数据科学导论 · 综合实验 1

文本分析

大众点评商户评论的情感分类与可视化

组员：成员A（数据与模型） | 成员B（文本可视化） | 成员C（统计可视化 / 交互 / 报告）
学号：_____ 班级：_____ 指导教师：_____
日期：2026 年 11 月 | 代码仓库：github.com/lovechen-520/text-analysis-exp1

11 项任务 · 19 张结果图 · 5 个 notebook

实验背景与数据

大众点评 yf_dianping：4,107,199 条评论，241,360 家商户

4,107,199
评论条数

241,360
有评论商户

1.9 GB
主数据 · 8 列

2003–2012
时间跨度

文件	规模	用途
preprocessed_ratings.csv	4,107,199 行 × 8 列，1.9 GB	主数据（任务 3–11）
restaurants.csv	243,247 行 × 2 列	商户名称检索
links.csv	243,247 行 × 2 列	点评 ID 映射（未使用）

主数据已完成任务 1、2 的清洗与导出，本实验直接使用并复核质量

字段：userId、restId、rating、rating_env / rating_flavor / rating_service、timestamp（毫秒）、comment

数据质量：三个必须先处理的问题

不识别这三点，标签、图表与结论都会失真

3.6 是伪值

1,127,570 行（27.45%）的 rating 由全局均值填充；真实评分只取整数 0–5，可用 rating==3.6 掩码剔除

2009 年前无评分

2009-07 前基本无有效星级；情感分类与时间趋势只能覆盖 2009-07 ~ 2012-02

店均样本极少

每店评论数中位仅 3 条；极化样本 ≥30 的商户只有 20,563 家，Top10 需设阈值

三个直接后果

① 监督学习必须剔除 3.6 伪值行；② 时间序列只能从 2009 年下半年开始；③ 商户排名必须用最小样本阈值 + Wilson 下界，否则会被 1–2 条评论的店刷榜。

数据质量决定了后续所有口径，而不是模型调参

标签构造：5 级评分 → 好评 / 差评

口径 A（主实验）与口径 B（对照）

评分	条数	标签
5 星	370,067	1 好评
4 星	1,351,432	1 好评
3 星	1,037,168	中性（剔除）
2 星	139,981	0 差评
1 星	80,966	0 差评
0 分	15	异常删除
3.6 伪值	1,127,570	无标签

口径 A：4–5 星→1，1–2 星→0，三星与 3.6 剔除
口径 B（对照）：4–5 星→1，1–3 星→0

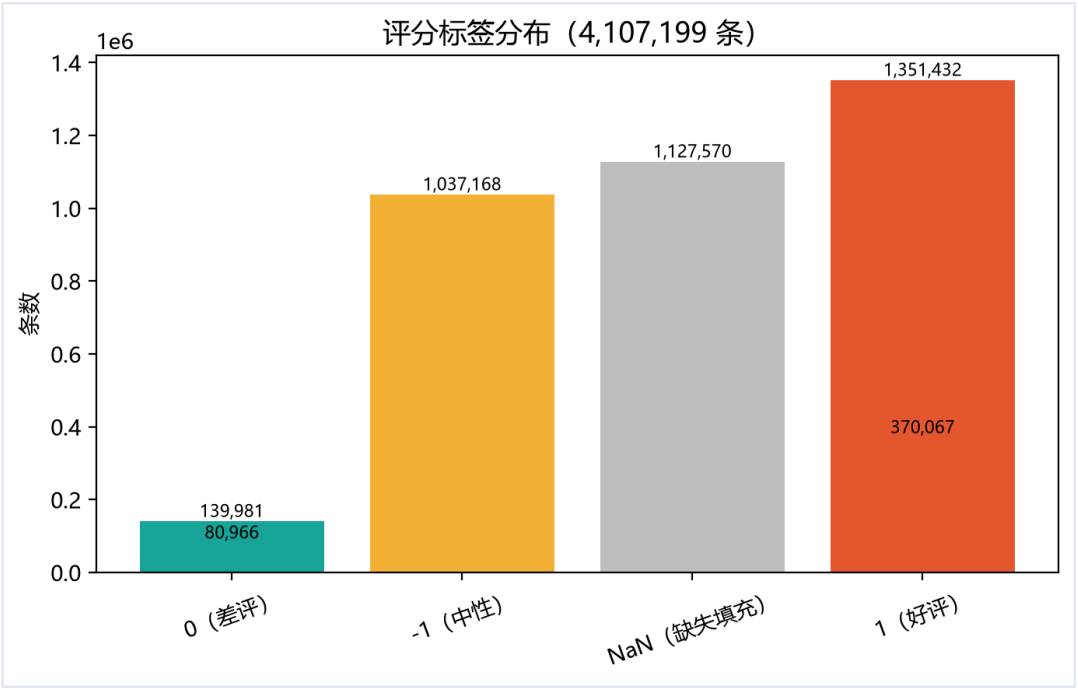


图 1 评分标签分布

有效评分 2,979,614 条：好评 1,721,499 / 差评 220,947，极化好评率 88.62%

文本清洗与分词

先规则清洗，再 jieba 分词，最后去停用词

01 清洗

去 URL、换行、标点与表情；仅保留中文、英文、数字

02 分词

jieba 精确模式 + 餐饮/点评领域词典（约 120 词）

03 去停用词

自建停用词表（约 500 词），过滤无意义词

原始评论	分词结果（去停用词）
这家的火锅很好吃，服务态度也不错，就是有点贵！！！	这家 火锅 很 好吃 服务态度 不错 有点 贵
服务员态度极差，上菜慢得要死，再也不会来了……	服务员 态度 极差 上菜 慢 要死 再也 不会 来
团购的套餐，性价比很高，停车也方便。	团购 套餐 性价比 很 高 停车 方便

全量 4,107,199 条 · 约 5.94 亿字符 · 16 进程 238 秒 · 词表 111 万 · 缓存 334.6 MB（2,979,614 行带标签样本）

分词结果缓存一次，供特征工程与词云复用

特征构造与数据划分

TF-IDF 主特征，Count 作为对照

特征	参数	用途
TF-IDF	word 1–2 gram，min_df=5，max_features=50,000，sublinear_tf	主模型特征
CountVectorizer	max_features=30,000	对照特征

60 万极化样本分层抽样（好评率 88.63%），按 8:2 划分：



训练样本

480,000

测试样本

120,000

TF-IDF 特征

50,000

特征矩阵：480,000 × 50,000（TF-IDF），训练与对比一次完成

模型对比：准确率与差评识别的权衡

口径 A，60 万抽样，TF-IDF / Count × 3 种算法

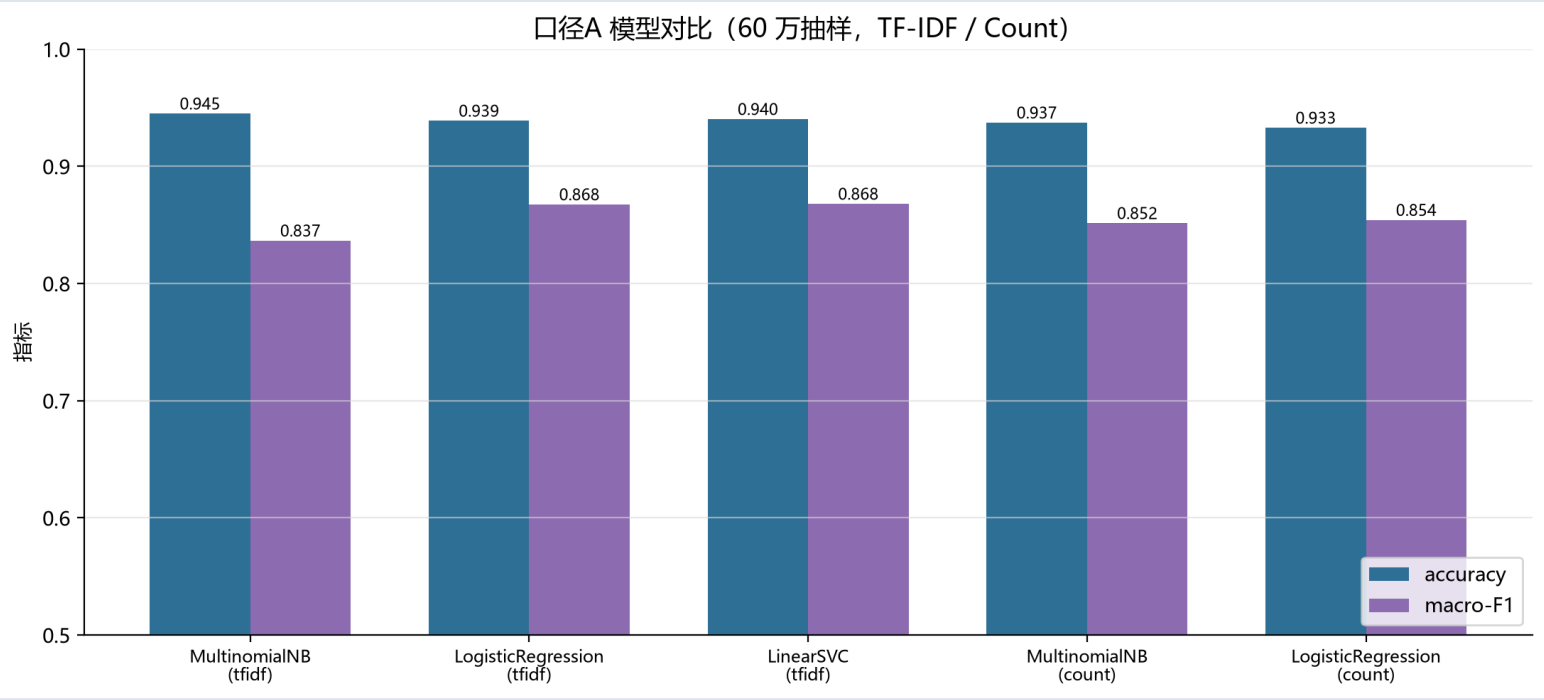


图 2 各模型 accuracy 与 macro-F1 对比

0.9403

LinearSVC · accuracy

macro-F1 0.868　差评 recall 0.88

朴素贝叶斯 accuracy 最高（0.9450），但差评召回仅 0.5732，偏向多数类。
LinearSVC / 逻辑回归 macro-F1 均达 0.868，差评召回提升到 0.88–0.90。

综合两类均衡性，选 LinearSVC 作为主模型

测试集评估与用户输入推理

20 万演示样本：accuracy 0.9430 · macro-F1 0.8700 · 差评 recall 0.8519

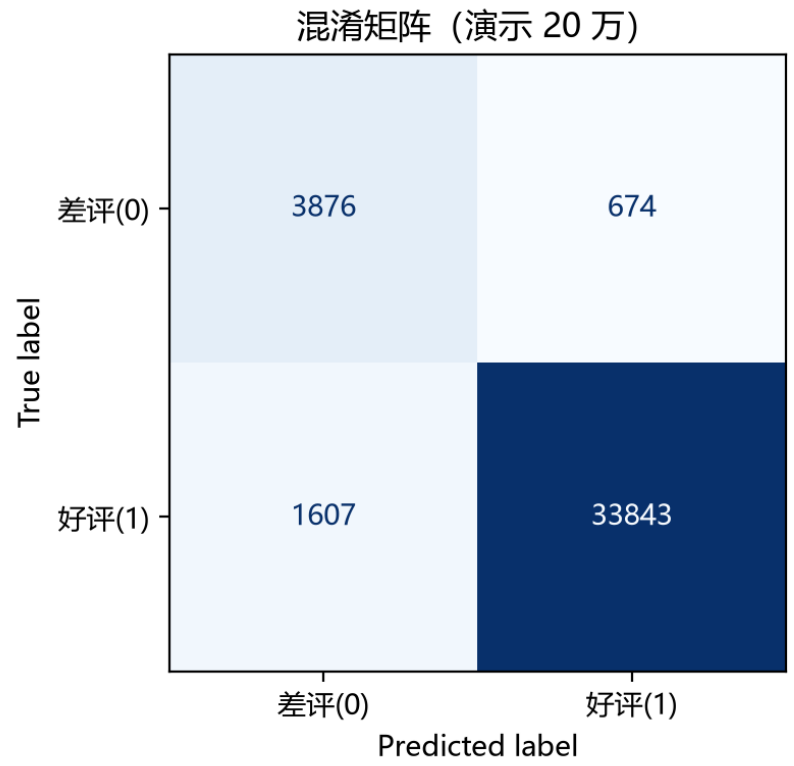


图 3 混淆矩阵（LinearSVC，20 万演示样本）

用户输入推理示例（同一套清洗 / 分词 / 模型）

“菜的味道非常好，服务也很周到，下次还会再来！”

好评

“难吃死了，服务态度极差，环境也很脏，再也不来了。”

差评

“环境一般，但菜的味道还不错，价格略贵，可以接受。”

好评

模型能抓住“味道不错”等主要极性，可直接用于新评论

口径对照与最终模型

口径 B（三星并入差评）说明标签口径的影响

口径 B：三星并入差评（60 万抽样）

模型	accuracy	macro-F1
MultinomialNB	0.7398	0.7210
LogisticRegression	0.7522	0.7474
LinearSVC	0.7419	0.7369

口径 B 类别更平衡，但三星文本语义中性、噪声大；其“全猜好评”基线为 57.8%，最佳 accuracy 0.7522 明显低于口径 A。

口径 A：全量 194 万极化样本（最终模型）

模型	accuracy	macro-F1
MultinomialNB	0.9475	0.8468
LogisticRegression	0.9395	0.8699
LinearSVC	0.9375	0.8657

训练 1,553,956 / 测试 388,490；逻辑回归 macro-F1 最高（0.8699），保存为最终推理模型。

同一测试口径下的 accuracy 对比（口径 B 的全猜好评基线为 57.8%）



三星并入差评引入标签噪声，口径 A 更合理；全量模型结果与 60 万一致

词云：好评与差评的语言差异

全部评论 / 好评（4–5 星）/ 差评（1–2 星）

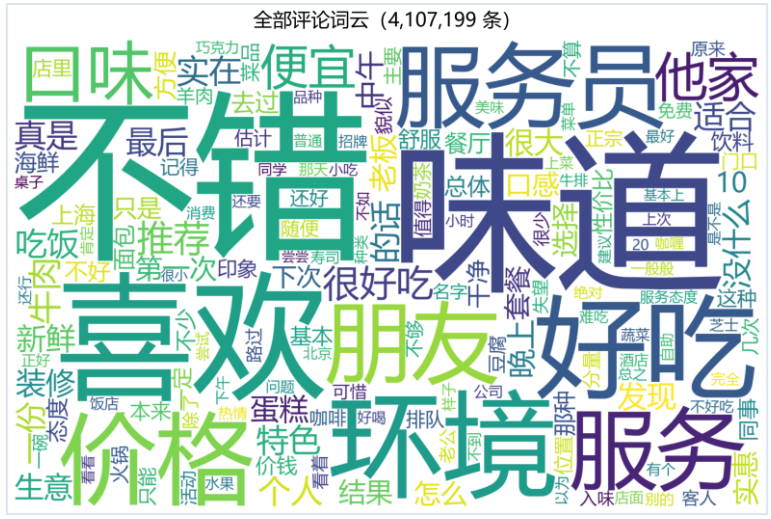


图 4 全部评论词云（4,107,199 条）



图 5 好评词云（1,721,499 条）



图 6 差评词云（220,947 条）

好评高频词 Top10

好吃 · 推荐 · 味道 · 服务 · 环境 · 喜欢 · 不错 · 价格 · 实惠 · 朋友

差评高频词 Top10

难吃 · 态度 · 服务员 · 贵 · 慢 · 失望 · 环境 · 差 · 服务 · 价格

好评偏“好吃 / 推荐 / 味道 / 服务”，差评偏“难吃 / 态度 / 服务员 / 贵 / 慢”

商户好评率 Top10 / Bottom10

极化样本≥30，Wilson 95% 下界排序，避免小样本刷榜

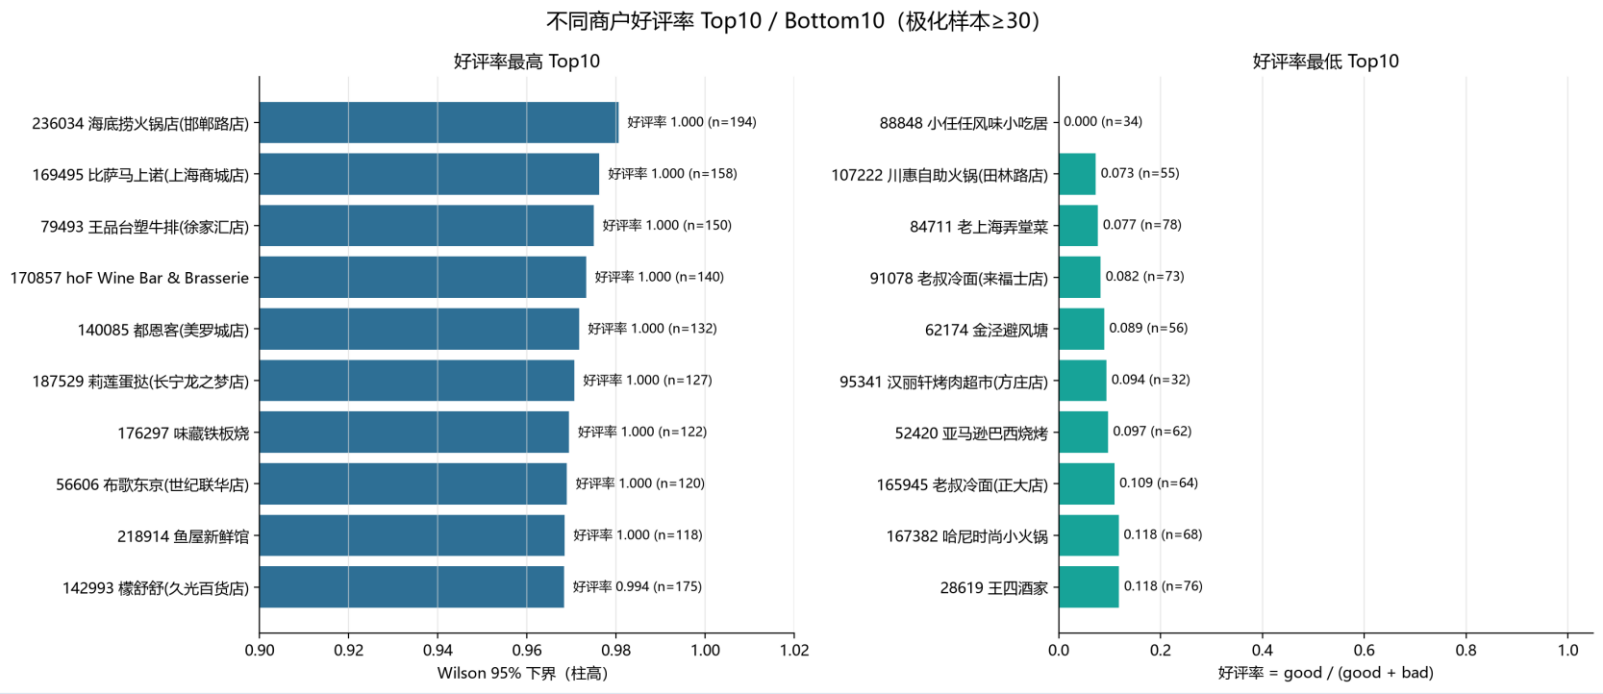


图 10 好评率最高 Top10 与最低 Bottom10

商户（Top10 节选）	n	好评率
海底捞(邯郸路店)	203	1.000
比萨马上诺(上海商城店)	174	1.000
王品台塑牛排(徐家汇店)	171	1.000
檬舒舒(久光百货店)	204	0.994

好评率 = 好评 /(好评 + 差评)；
头部 10 家均为 100%（Wilson 下界区分样本量）；
Bottom10 为 0%–12%，差异真实存在。

样本量控制 + 置信下界，才能让“好评率排名”有意义

时间趋势与评分结构

周滚动好评率 + 环境 / 口味 / 服务雷达图

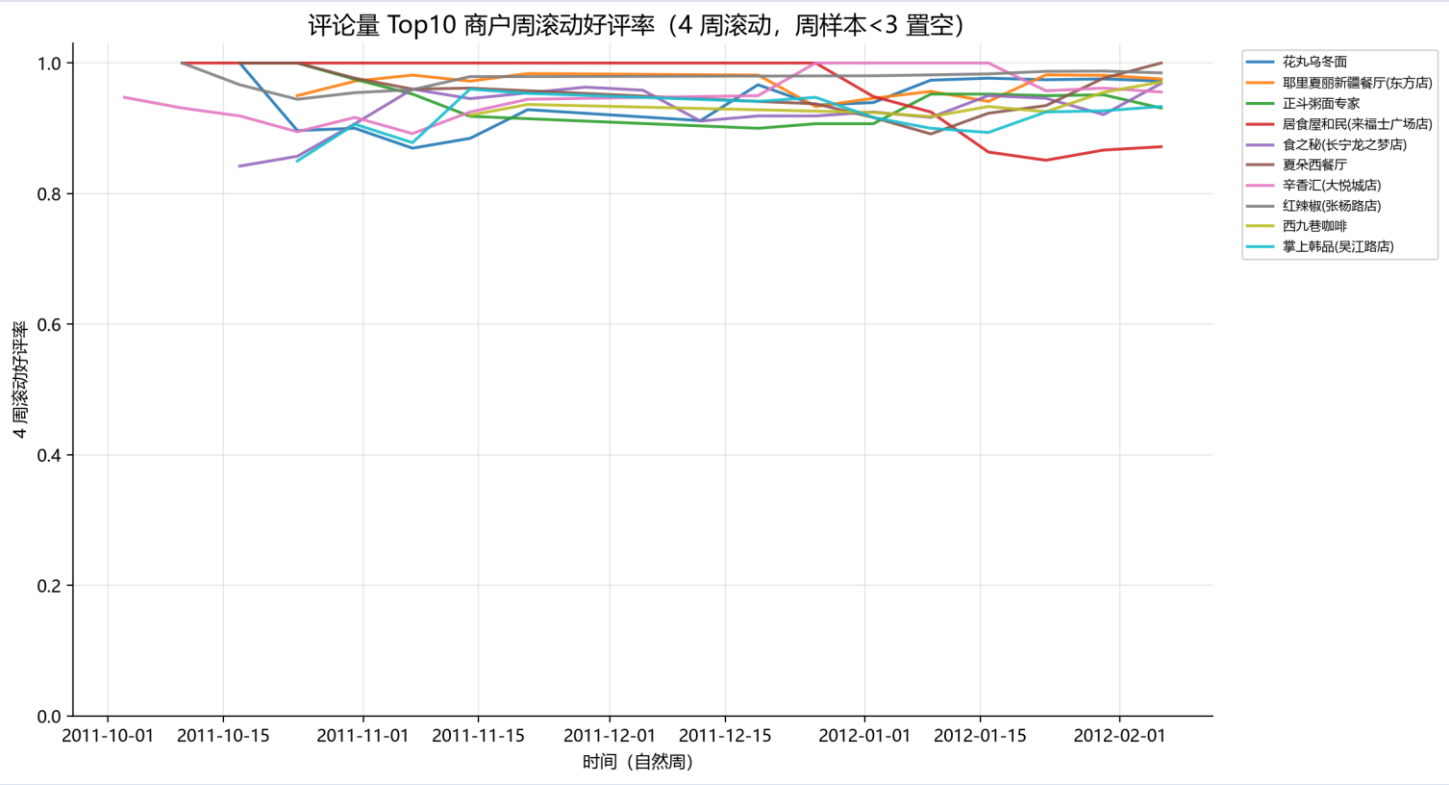


图 11 评论量 Top10 商户周滚动好评率（4 周滚动，周样本<3 置空）

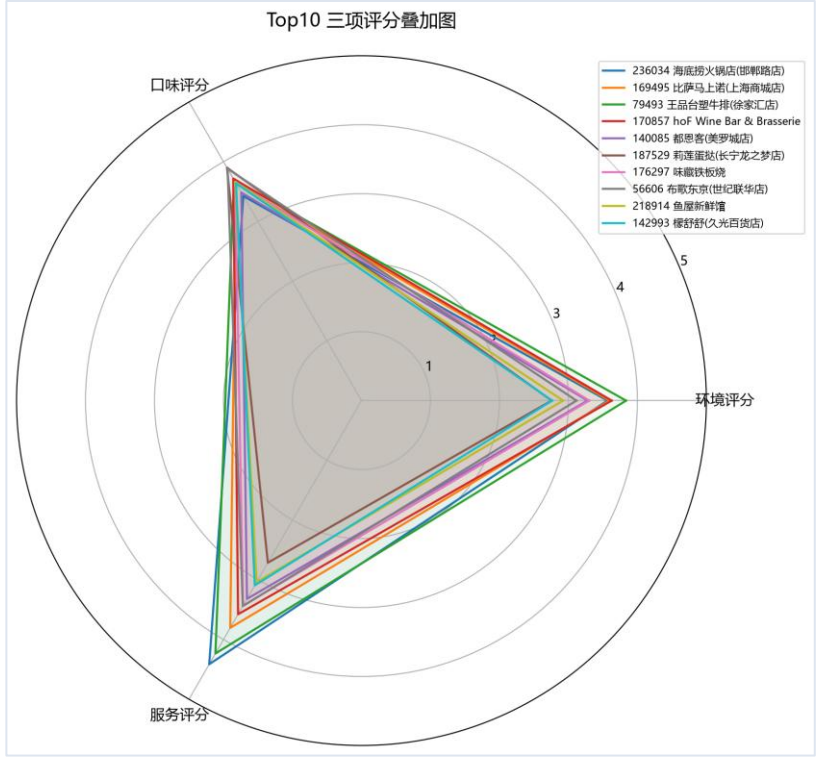


图 13 Top10 三项评分叠加图

周好评率在 0.85–1.0 波动；三项评分中口味最高、环境≈服务

关键词查询与单店分析

示例：关键词“湘” → 57℃湘(无限度广场店)

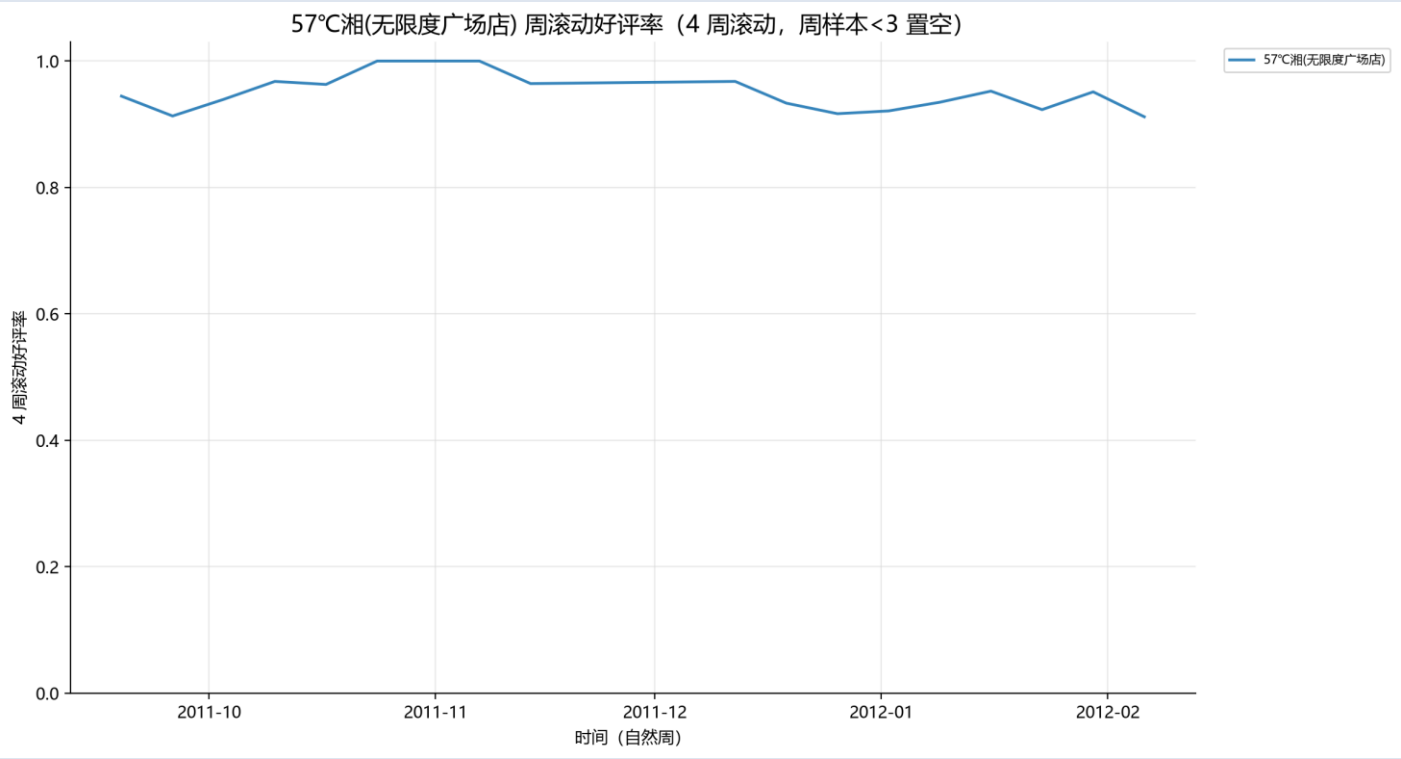


图 19 该店周滚动好评率（20 个活跃周）

1. 输入关键词（名称或评论）
2. 候选列表按样本量排序
3. 选择商户 → 四张图
4. 词云 / 好评率 / 雷达图 / 周趋势

演示店：207 条评论 / 160 条极化样本 / 20 个活跃周；
好评率 0.944，环境 4.1 / 口味 4.4 / 服务 4.0。

0.944

该店好评率（全站 88.62%）

search_restaurants() + 单店四图，可复用到任意商户

结论与分工

完成 11 项任务；数据质量与口径决定结论

完成度	11 项任务全部实现：清洗分词、TF-IDF、3 模型对比、词云、商户可视化、单店查询
主结果	口径 A：LinearSVC accuracy 0.9403 / macro-F1 0.868；全量 194 万 0.9395 / 0.8699
关键判断	3.6 伪值必须掩码剔除；2009-07 前无评分；Top10 需样本阈值 + Wilson 平滑
可视化	好评 88.62%；词云呈“口味 > 环境 ≈ 服务”；单店四图可交互复用

不足与改进

数据止于 2012 年且 2009-07 前无评分；未使用预训练模型对比；评论与星级存在少量不一致；商户名称缺失 14%。

分工与致谢

成员A：数据与模型
成员B：文本可视化
成员C：统计可视化 + 交互 + 报告 / PPT

谢谢！欢迎提问