数据科学导论 · 综合实验 1

文本分析

大众点评商户评论的情感分类与可视化

组员：成员A（数据与模型） | 成员B（文本可视化） | 成员C（统计可视化 / 交互 / 报告）
学号：_____ 班级：_____ 指导教师：_____
日期：2026 年 11 月 | 代码仓库：github.com/lovechen-520/text-analysis-exp1

11 项任务 · 19 张结果图 · 5 个 notebook

实验背景与数据

大众点评 yf_dianping：4,107,199 条评论，241,360 家商户

4,107,199
评论条数

241,360
有评论商户

1.9 GB
主数据 · 8 列

2003–2012
时间跨度

文件	规模	用途
preprocessed_ratings.csv	4,107,199 行 × 8 列，1.9 GB	主数据（任务 3–11）
restaurants.csv	243,247 行 × 2 列	商户名称检索
links.csv	243,247 行 × 2 列	点评 ID 映射（未使用）

主数据已完成任务 1、2 的清洗与导出，本实验直接使用并复核质量

字段：userId、restId、rating、rating_env / rating_flavor / rating_service、timestamp（毫秒）、comment

数据质量：三个必须先处理的问题

不识别这三点，标签、图表与结论都会失真

3.6 是伪值

1,127,570 行（27.45%）的 rating 由全局均值填充；真实评分只取整数 0–5，可用 rating==3.6 掩码剔除

2009 年前无评分

2009-07 前基本无有效星级；情感分类与时间趋势只能覆盖 2009-07 ~ 2012-02

店均样本极少

每店评论数中位仅 3 条；极化样本 ≥30 的商户只有 20,563 家，Top10 需设阈值

三个直接后果

① 监督学习必须剔除 3.6 伪值行；② 时间序列只能从 2009 年下半年开始；③ 商户排名必须用最小样本阈值 + Wilson 下界，否则会被 1–2 条评论的店刷榜。

数据质量决定了后续所有口径，而不是模型调参

标签构造：5 级评分 → 好评 / 差评

口径 A（主实验）与口径 B（对照）

评分	条数	标签
5 星	370,067	1 好评
4 星	1,351,432	1 好评
3 星	1,037,168	中性（剔除）
2 星	139,981	0 差评
1 星	80,966	0 差评
0 分	15	异常删除
3.6 伪值	1,127,570	无标签

口径 A：4–5 星→1，1–2 星→0，三星与 3.6 剔除
口径 B（对照）：4–5 星→1，1–3 星→0

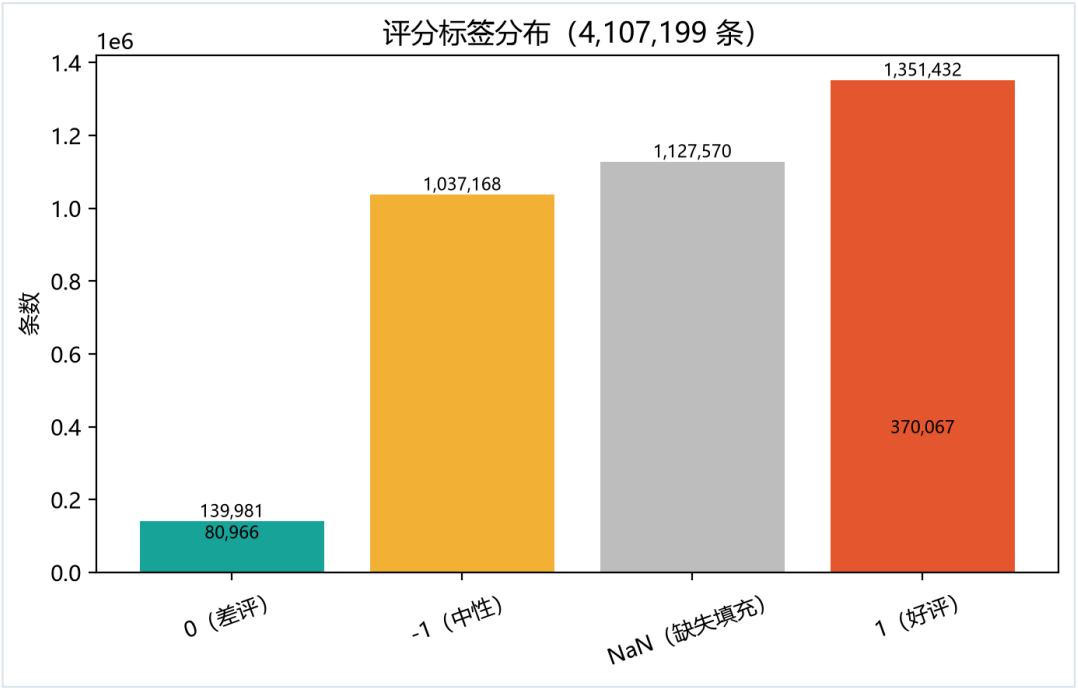


图 1 评分标签分布

有效评分 2,979,614 条：好评 1,721,499 / 差评 220,947，极化好评率 88.62%

文本清洗与分词

先规则清洗，再 jieba 分词，最后去停用词

01 清洗

去 URL、换行、标点与表情；仅保留中文、英文、数字

02 分词

jieba 精确模式 + 餐饮/点评领域词典（约 120 词）

03 去停用词

自建停用词表（约 500 词），过滤无意义词

原始评论	分词结果（去停用词）
这家的火锅很好吃，服务态度也不错，就是有点贵！！！	这家 火锅 很 好吃 服务态度 不错 有点 贵
服务员态度极差，上菜慢得要死，再也不会来了……	服务员 态度 极差 上菜 慢 要死 再也 不会 来
团购的套餐，性价比很高，停车也方便。	团购 套餐 性价比 很 高 停车 方便

全量 4,107,199 条 · 约 5.94 亿字符 · 16 进程 238 秒 · 词表 111 万 · 缓存 334.6 MB（2,979,614 行带标签样本）

分词结果缓存一次，供特征工程与词云复用

特征构造与数据划分

TF-IDF 主特征，Count 作为对照

特征	参数	用途
TF-IDF	word 1–2 gram，min_df=5，max_features=50,000，sublinear_tf	主模型特征
CountVectorizer	max_features=30,000	对照特征

60 万极化样本分层抽样（好评率 88.63%），按 8:2 划分：



训练样本

480,000

测试样本

120,000

TF-IDF 特征

50,000

特征矩阵：480,000 × 50,000（TF-IDF），训练与对比一次完成

模型对比：准确率与差评识别的权衡

口径 A，60 万抽样，TF-IDF / Count × 3 种算法

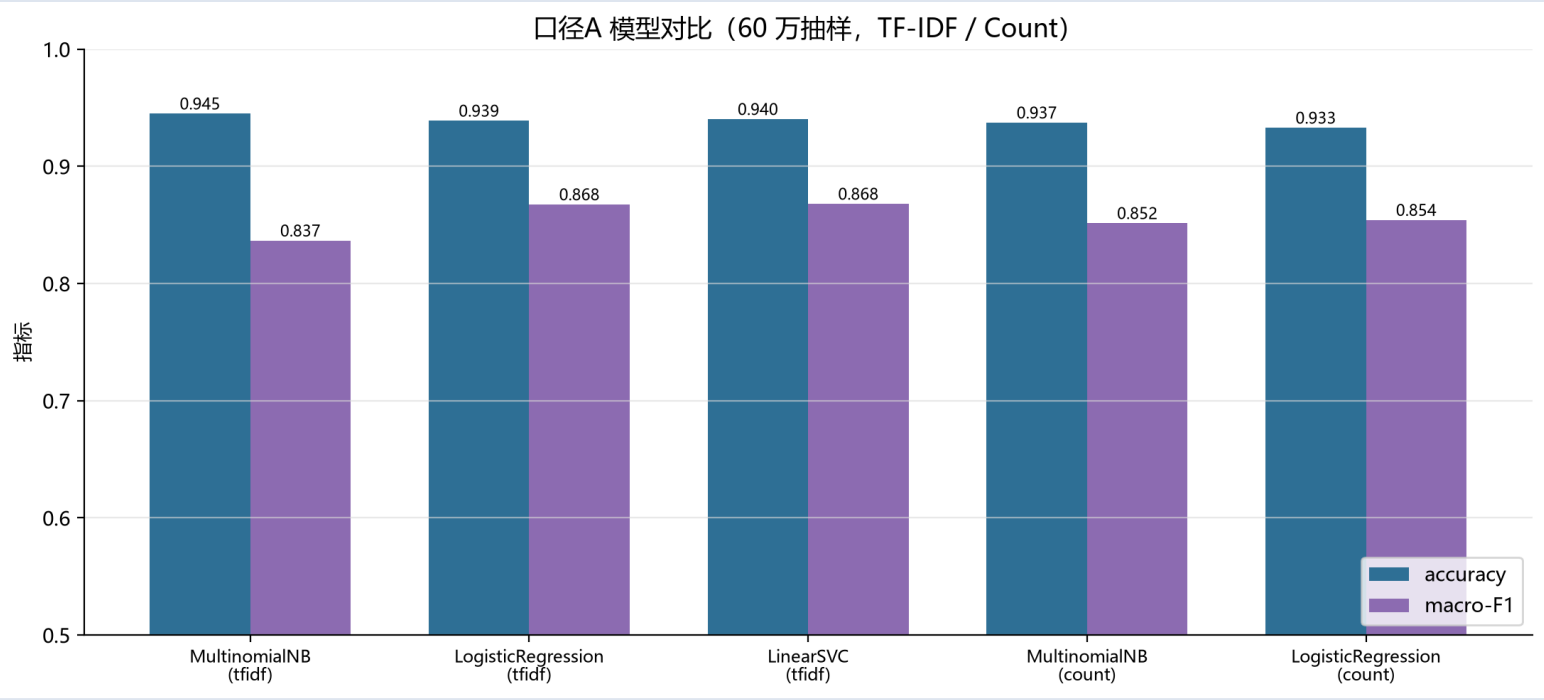


图 2 各模型 accuracy 与 macro-F1 对比

0.9403

LinearSVC · accuracy

macro-F1 0.868　差评 recall 0.88

朴素贝叶斯 accuracy 最高（0.9450），但差评召回仅 0.5732，偏向多数类。
LinearSVC / 逻辑回归 macro-F1 均达 0.868，差评召回提升到 0.88–0.90。

综合两类均衡性，选 LinearSVC 作为主模型

测试集评估与用户输入推理

20 万演示样本：accuracy 0.9430 · macro-F1 0.8700 · 差评 recall 0.8519

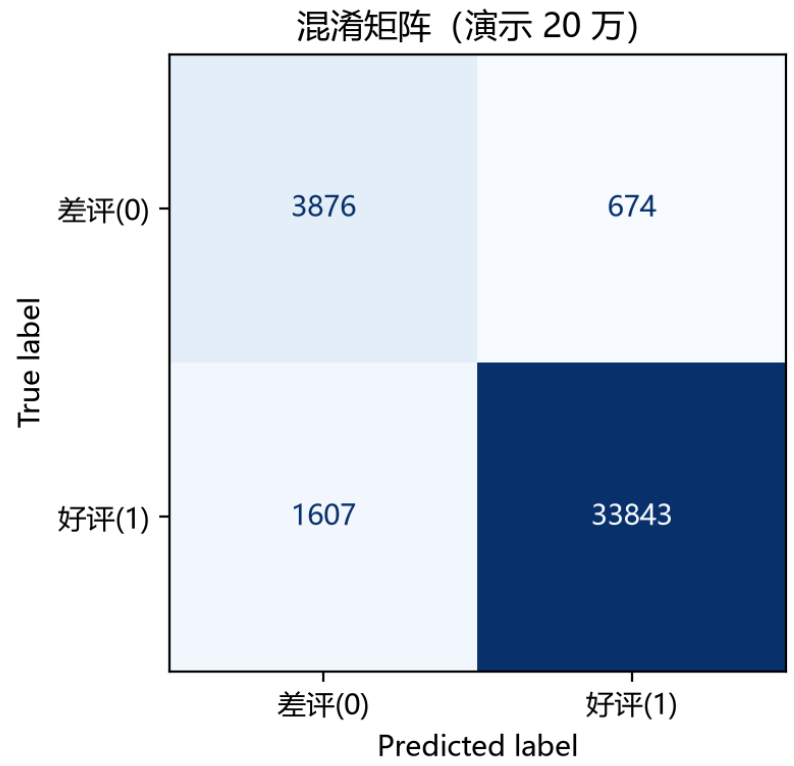


图 3 混淆矩阵（LinearSVC，20 万演示样本）

用户输入推理示例（同一套清洗 / 分词 / 模型）

“菜的味道非常好，服务也很周到，下次还会再来！”

好评

“难吃死了，服务态度极差，环境也很脏，再也不来了。”

差评

“环境一般，但是菜的味道还不错，价格略贵，可以接受。”

好评

模型能抓住“味道不错”等主要极性，可直接用于新评论

口径对照与最终模型

口径 B（三星并入差评）说明标签口径的影响

口径 B：三星并入差评（60 万抽样）

模型	accuracy	macro-F1
MultinomialNB	0.7398	0.7210
LogisticRegression	0.7522	0.7474
LinearSVC	0.7419	0.7369

口径 B 类别更平衡，但三星文本语义中性、噪声大；其“全猜好评”基线为 57.8%，最佳 accuracy 0.7522 明显低于口径 A。

口径 A：全量 194 万极化样本（最终模型）

模型	accuracy	macro-F1
MultinomialNB	0.9475	0.8468
LogisticRegression	0.9395	0.8699
LinearSVC	0.9375	0.8657

训练 1,553,956 / 测试 388,490；逻辑回归 macro-F1 最高（0.8699），保存为最终推理模型。

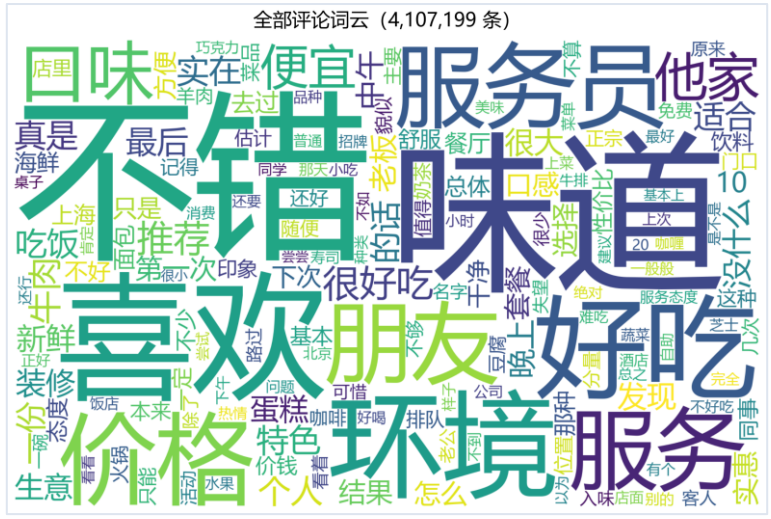
同一测试口径下的 accuracy 对比（口径 B 的全猜好评基线为 57.8%）



三星并入差评引入标签噪声，口径 A 更合理；全量模型结果与 60 万一致

词云：好评与差评的语言差异

全部评论 / 好评（4–5 星）/ 差评（1–2 星）


全部评论词云（4,107,199 条）
不错
味道
喜欢
好吃
朋友
价格
环境
服务
服务员
口味
便宜
他家
推荐
很好吃
没什么
这种
适合
真是
最后
实在
特色
发现
蛋糕
装修
生意
结果
怎么
实惠
同事
客人
位置
态度
排队
值得
晚上
吃饭
餐厅
下次
第一次
不好吃
不行
失望
难吃
贵
慢
差
太差了
垃圾
恶心
退钱
投诉
倒胃口
再也不来了
不会再来了
不值这个价
不新鲜
变质
拉肚子
吃坏肚子
服务态度
上菜慢
等了很久
没人管
态度差
服务员态度差
环境差
脏
乱
苍蝇
蟑螂
老鼠
卫生差
不卫生
不干净
发霉
异味
臭
油腻
太油
太咸
太淡
没味道
味道差
味道一般
不如
不如以前
不如从前
变味了
缩水
分量少
量少
贵了
太贵了
不值
不值得
性价比低
坑人
宰人
黑心
黑店
骗人
欺骗
虚假宣传
名不副实
失望透顶
后悔
后悔去
后悔来
后悔点
后悔吃
后悔了
后悔没听
后悔没看
后悔没来
后悔没去
后悔没选
后悔没点
后悔没吃
后悔没买
后悔没带
后悔没早点来
后悔没早点去
后悔没早点吃
后悔没早点买
后悔没早点带
后悔没早点听
后悔没早点看
后悔没早点选
后悔没早点点
后悔没早点吃饭
后悔没早点吃东西
后悔没早点吃饭了
后悔没早点吃东西了
后悔没早点吃饭了吗
后悔没早点吃东西了吗
后悔没早点吃饭了吗？
后悔没早点吃东西了吗？
后悔没早点吃饭了吗？！
后悔没早点吃东西了吗？！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！！！
后悔没早点吃东西了吗？！！！！
后悔没早点吃饭了吗？！！！！！
后悔没早点吃东西了吗？！！！！！
后悔没早点吃饭了吗？！！！！！！
后悔没早点吃东西了吗？！！！！！！
后悔没早点吃饭了吗？！！！！！！！
后悔没早点吃东西了吗？！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃东西了吗？！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！！
后悔没早点吃饭了吗？！！！
后悔没早点吃东西了吗？！！！
后悔没早点吃饭了吗？！！
后悔没早点吃东西了吗？！

商户好评率 Top10 / Bottom10

极化样本≥30，Wilson 95% 下界排序，避免小样本刷榜

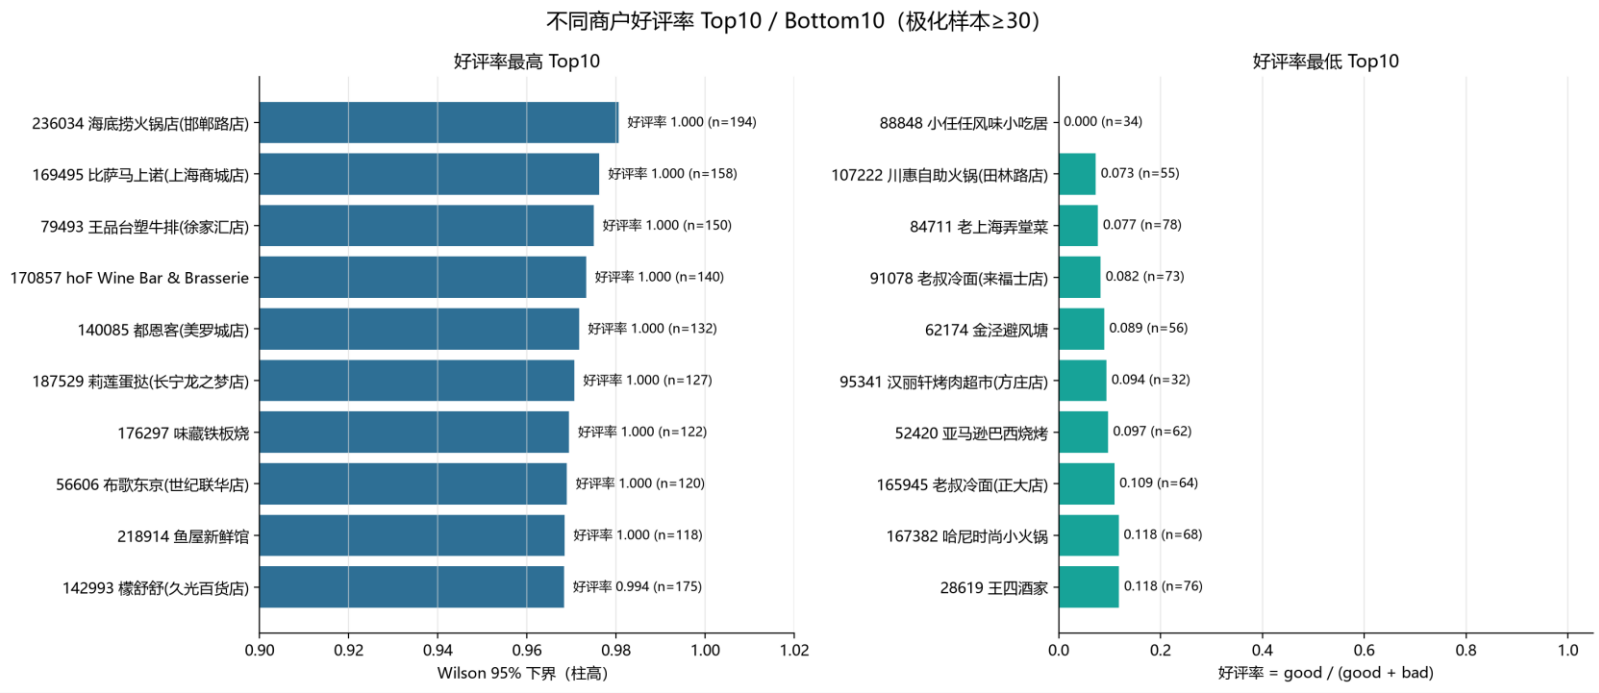


图 10 好评率最高 Top10 与最低 Bottom10

商户（Top10 节选）	n	好评率
海底捞(邯郸路店)	203	1.000
比萨马上诺(上海商城店)	174	1.000
王品台塑牛排(徐家汇店)	171	1.000
檬舒舒(久光百货店)	204	0.994

头部 10 家好评率均为 100%，用 Wilson 下界区分样本量；
Bottom10 好评率 0%–12%，差异真实存在而不是随机波动。

样本量控制 + 置信下界，才能让“好评率排名”有意义

时间趋势与评分结构

周滚动好评率 + 环境 / 口味 / 服务雷达图

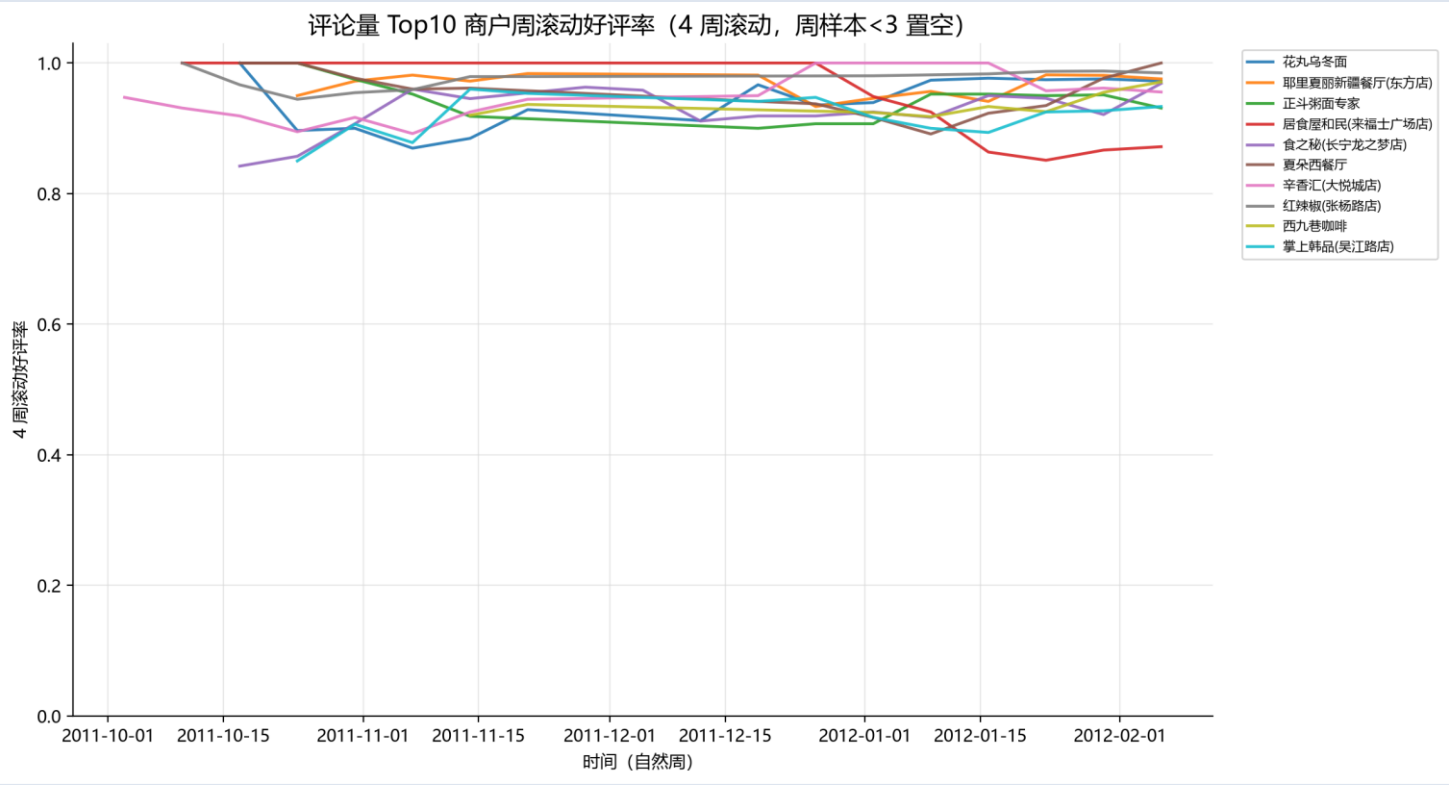


图 11 评论量 Top10 商户周滚动好评率（4 周滚动，周样本<3 置空）

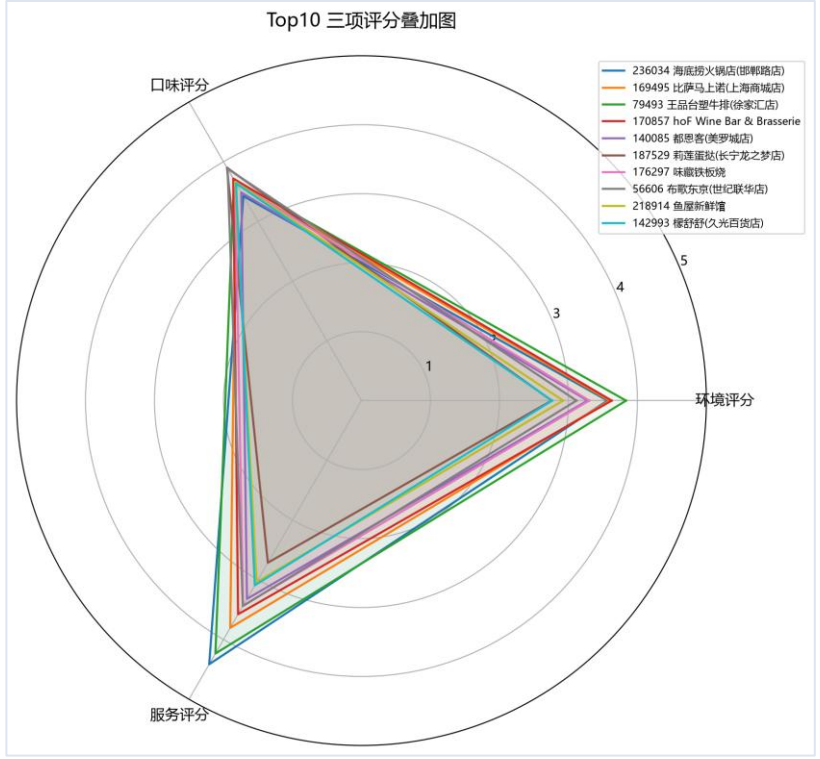


图 13 Top10 三项评分叠加图

周好评率在 0.85–1.0 波动；三项评分中口味最高、环境≈服务

关键词查询与单店分析

示例：关键词“湘” → 57℃湘(无限度广场店)

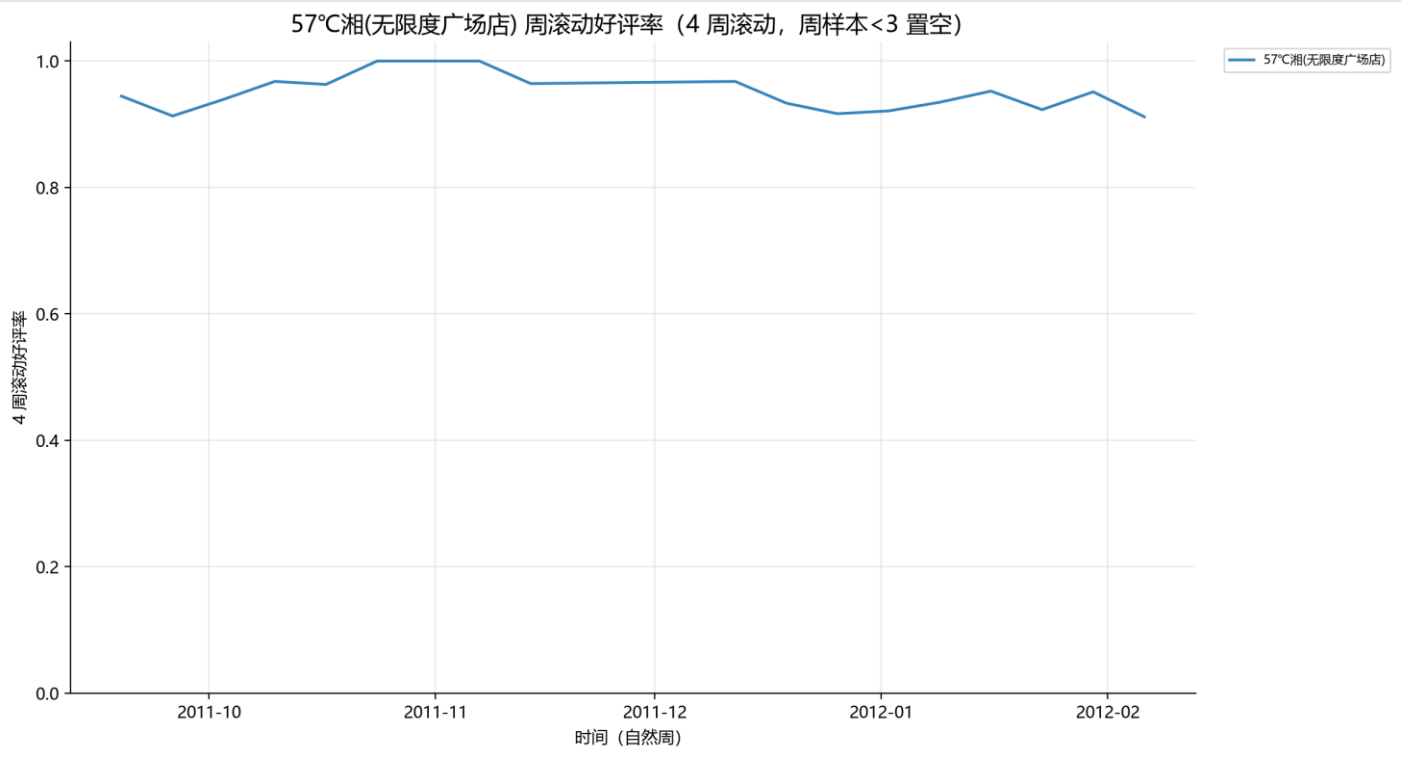


图 19 该店周滚动好评率（20 个活跃周）

1. 输入关键词（名称或评论）
2. 候选列表按样本量排序
3. 选择商户 → 四张图
4. 词云 / 好评率 / 雷达图 / 周趋势

演示店：207 条评论 / 160 条极化样本 / 20 个活跃周；
好评率 0.944，环境 4.1 / 口味 4.4 / 服务 4.0。

0.944

该店好评率（全站 88.62%）

search_restaurants() + 单店四图，可复用到任意商户

结论与分工

完成 11 项任务；数据质量与口径决定结论

完成度 11 项任务全部实现：清洗分词、TF-IDF、3 模型对比、词云、商户可视化、单店查询

主结果 口径 A：LinearSVC accuracy 0.9403 / macro-F1 0.868；全量 194 万 0.9395 / 0.8699

关键判断 3.6 伪值必须掩码剔除；2009-07 前无评分；Top10 需样本阈值 + Wilson 平滑

可视化 好评 88.62%；词云呈“口味 > 环境 ≈ 服务”；单店四图可交互复用

不足与改进

数据止于 2012 年且 2009-07 前无评分；未使用预训练模型对比；评论与星级存在少量不一致；商户名称缺失 14%。

分工与致谢

成员A：数据与模型
成员B：文本可视化
成员C：统计可视化 + 交互 + 报告 / PPT

谢谢！欢迎提问